

Laporan Temu-Balik Informasi

Perbandingan Algoritma Kompresi Variable Byte Encoding dengan Elias-Gamma Coding pada Koleksi arXiv

Lyzander Marciano Andrylie – 2106750755

1. Pendahuluan

Algoritma kompresi integer dibagi menjadi 2 kategori berdasarkan tingkat representasi integer yang dikompres, yaitu *bit-level coding* dan *byte-level coding*. *Bit-level coding* adalah proses kompresi yang menggunakan representasi di tingkat bit dari bilangan bulat yang dikompres. Di sisi lain, *Byte-level coding* adalah proses kompresi yang menggunakan representasi di tingkat byte dari bilangan bulat yang dikompres. Keduanya memiliki kelebihan dan kekurangan masing-masing.

Berdasarkan hal tersebut, penulis melakukan eksperimen terhadap sampel dataset dari kumpulan abstrak dokumen di arXiv dalam bahasa Inggris. Total dokumen yang ada sebanyak kurang lebih 250.000 dokumen yang tersebar di 25 folder, di mana masing-masing folder berisi kurang lebih 10.000 dokumen. Dalam percobaan ini penulis akan menggunakan 2 algoritma: (1) variable byte encoding sebagai *byte-level encoding* dan (2) Elias-gamma coding sebagai *bit-level encoding*. Setelah itu, analisis terhadap waktu *indexing* dan ukuran *file indices* yang terbentuk akan dilakukan terhadap hasil percobaan.

2. Pembahasan

Percobaan dilakukan pada komputer ASUS TUF Dash F15 FX517ZC dengan spesifikasi CPU 12th Gen Intel(R) Core(TM) i5-12450H 2.00 GHz, RAM 16 GB, dan sistem operasi Windows 11. Hasil percobaan dari algoritma kompresi variable byte encoding dengan Elias-gamma coding pada koleksi adalah sebagai berikut.

Algoritma	Waktu Indexing	Semua File	Main Index File
Variable byte encoding	31,4 menit	60,5 MB	19,84 MB
Elias-gamma coding	29,7 menit	60,8 MB	19,79 MB

Tabel 2.1 Perbandingan Algoritma Kompresi Variable Byte Encoding dengan Elias-Gamma Coding pada Koleksi arXiv

Berdasarkan hasil percobaan tersebut, penggunaan algoritma kompresi variable byte encoding sebagai *byte-level encoding* dan Elias-gamma coding sebagai *bit-level encoding* tidak memiliki perbedaan yang cukup signifikan. Hal ini dipengaruhi oleh jumlah dokumen pada koleksi arXiv yang digunakan yang tidak terlalu besar. Hal ini dapat dilihat dari waktu *indexing* dengan durasi yang berdekatan dengan selisih hanya 1,7 menit. Walaupun Elias-gamma coding memerlukan operasi manipulasi bit untuk menghasilkan bytes yang sesuai, operasi tersebut tidak terlalu berpengaruh pada koleksi yang kecil. Kemudian, besar file yang dihasilkan oleh variable byte encoding sedikit lebih kecil dibandingkan dengan Elias-gamma coding. Hal ini dipengaruhi oleh besar *intermediate index* yang berbeda. Secara umum, integer yang lebih kecil dari 16

lebih baik di-*encode* dengan Elias-gamma agar dapat direpresentasikan kurang dari 1 byte (8 bit) sedemikian hingga menghemat penyimpanan yang diperlukan. Di sisi lain, integer yang lebih besar dari 16 lebih baik di-*encode* dengan variable byte encoding karena algoritma tersebut dapat merepresentasikan bilangan yang lebih besar dengan jumlah bit yang lebih kecil, misalnya 8 bit dapat merepresentasikan 0-127. Namun, berkaitan dengan *compression rate* pada main index file, Elias-gamma coding menghasilkan file sedikit lebih kecil dibandingkan dengan variable byte encoding. Hal ini dapat terjadi karena *bit-level coding* cenderung menghasilkan kompresi yang lebih baik dibandingkan dengan *byte-level coding*. Selain itu, hal ini juga dapat menandakan *gap list* pada koleksi tersebut memiliki jarak yang berdekatan sedemikian hingga penggunaan Elias-gamma menjadi cukup efektif.

$$\text{compression rate} = \frac{\text{ukuran data awal}}{\text{ukuran data hasil kompresi}}$$

Berkaitan dengan waktu *query*, berikut adalah hasil percobaan yang dilakukan pada query.

Query	Variable Byte Encoding	Elias-Gamma Coding
(cosmological AND (quantum OR continuum)) AND geodesics	$3,25 * 10^{-4}$ detik	$3,16 * 10^{-4}$ detik
((photon AND colliders AND (order OR accuracy)) OR (sparse AND (game OR theory) DIFF boson) OR (system AND matter AND (friction OR quantum))) DIFF (cosmological OR rotation) AND ((photon AND colliders AND (order OR accuracy) AND (quark OR gluon) AND (production OR distribution)) OR (sparse AND (game OR theory) DIFF boson AND (graph OR proof)) OR (system AND matter AND (friction OR quantum) AND (fluid OR motion) AND (Earth OR Mars))) DIFF (cosmological OR rotation OR particle)	$7,21 * 10^{-4}$ detik	$4,74 * 10^{-4}$ detik

Tabel 2.2 Perbandingan Waktu Eksekusi Query Algoritma Kompresi Variable Byte Encoding dengan Elias-Gamma Coding pada Koleksi arXiv

Berdasarkan percobaan di atas, waktu eksekusi dari kedua algoritma cukup berdekatan. Hal ini disebabkan query yang tidak terlalu besar dan koleksi arXiv yang cukup kecil. Hal ini juga menandakan bahwa penggunaan kedua algoritma tersebut tidak terlalu berpengaruh terhadap waktu eksekusi query.

3. Kesimpulan

Berdasarkan hasil percobaan yang dilakukan, penggunaan algoritma kompresi variable byte encoding sebagai *byte-level encoding* dan Elias-gamma coding sebagai *bit-level encoding* pada koleksi dokumen arXiv tidak menunjukkan perbedaan yang signifikan. Waktu *indexing* dari kedua algoritma hanya berbeda 1,7 menit, dengan variable byte encoding sedikit lebih lambat. Di sisi lain, ukuran file indeks yang dihasilkan oleh Elias-gamma coding sedikit lebih besar dibandingkan variable byte encoding. Dari sisi *compression rate*, Elias-Gamma menghasilkan kompresi yang lebih baik pada main index file. Kemudian, waktu eksekusi query pada kedua algoritma juga menunjukkan perbedaan yang kecil. Hal ini tentunya dipengaruhi oleh ukuran query dan dataset yang tidak terlalu besar. Secara keseluruhan, kedua algoritma memiliki performa yang mirip dalam percobaan ini.